

Act 3 Aprendizaje automático en finanzas

Ejercicio 2 Protección de datos en instituciones financieras

Ejercicio 3 Modelos y algoritmos de aprendizaje automático en finanzas

Nombre del estudiante: [Completar]

Matrícula: [Completar]

Curso: [Completar]

Fecha: 7 de septiembre de 2026

Ejercicio 2 Protección de datos en instituciones financieras

En México, una institución financiera privada debe proteger los datos de sus clientes durante la recolección, el uso, el almacenamiento, la transferencia y la eliminación. CONDUSEF orienta y protege a los usuarios financieros, pero la autoridad federal responsable de vigilar la ley general de datos personales en posesión de particulares es actualmente la Secretaría Anticorrupción y Buen Gobierno. La propia CONDUSEF recuerda que las entidades financieras deben ajustarse a la Ley Federal de Protección de Datos Personales en Posesión de los Particulares, LFPDPPP (CONDUSEF, 2026; Cámara de Diputados, 2025a).

Norma	Contenido relevante
LFPDPPP	Exige tratamiento lícito y proporcional, aviso de privacidad, consentimiento cuando corresponda, medidas de seguridad, atención de vulneraciones y mecanismos para ejercer derechos de acceso, rectificación, cancelación y oposición. Los datos sensibles requieren protección reforzada.
Ley para Regular las Sociedades de Información Crediticia	Regula la integración, consulta, conservación y corrección de historiales crediticios. Exige información completa y veraz, autorización en los supuestos previstos y procedimientos para reclamar registros incorrectos.
Ley de Protección y Defensa al Usuario de Servicios Financieros	Define la función de CONDUSEF, protege derechos e intereses de los usuarios y establece vías de consulta, conciliación y defensa. Complementa la privacidad con deberes de transparencia y trato adecuado.

Implicaciones para el análisis financiero

Un modelo de crédito, fraude o segmentación no puede comenzar con la idea de usar todos los datos disponibles. Primero debe definirse una finalidad legítima y documentada. Después se deben limitar las variables, anonimizar o seudonimizar cuando sea posible, restringir accesos, conservar bitácoras y establecer plazos de retención. También se debe verificar la calidad de los datos, porque un registro incorrecto puede producir una decisión desfavorable para una persona. La transparencia del aviso de privacidad y la posibilidad de corregir información son parte del control del riesgo del modelo, no solo requisitos administrativos.

Conclusión

La protección de datos sostiene la confianza en el sistema financiero y reduce riesgos de fraude, discriminación, robo de identidad y decisiones basadas en información incorrecta. Cumplir la ley exige unir controles jurídicos, seguridad de la información y validación técnica del modelo.

Reflexión personal: escribe 4 a 6 líneas sobre qué dato financiero te parecería más delicado y qué control aplicarías.

Ejercicio 3 Modelos de aprendizaje automático en finanzas

Los modelos de aprendizaje automático encuentran relaciones en datos históricos para predecir, clasificar o agrupar observaciones. En finanzas se aplican a riesgo de crédito, fraude, precios, segmentación y portafolios. Su ventaja sobre una regresión lineal es que pueden capturar no linealidades e interacciones; su principal costo suele ser menor interpretabilidad, mayor consumo de datos y una validación más exigente (Financial Stability Board, 2017).

Regresión lineal como referencia

La regresión lineal estima una relación promedio mediante coeficientes. Es rápida, fácil de auditar y útil cuando la relación es aproximadamente lineal y el objetivo es explicar cómo cambia una variable. Sus límites aparecen cuando existen umbrales, interacciones complejas o patrones temporales no lineales. También depende de supuestos sobre la forma funcional y los errores.

Modelo	Propósito	Aplicaciones financieras	Ventaja y límite
Árbol de decisión	Divide los datos mediante reglas sucesivas hasta producir una predicción o clase.	Aprobación de crédito, clasificación de riesgo y alertas de fraude.	Es visual e interpretable, pero un árbol profundo puede sobreajustarse.
Bosque aleatorio	Combina muchos árboles entrenados con muestras y variables aleatorias.	Probabilidad de incumplimiento, fraude y selección de variables.	Suele ser preciso y robusto; la explicación es menos directa que en un solo árbol (Breiman, 2001).
Red neuronal artificial	Aprende capas de transformaciones no lineales.	Scoring, señales de mercado, fraude y estimación de relaciones complejas.	Modela patrones flexibles, pero necesita datos, ajuste y controles de explicabilidad.

Los árboles y bosques trabajan bien con variables numéricas y categóricas, capturan umbrales y no requieren una relación lineal. En crédito o fraude conviene medir desempeño fuera de muestra, revisar desbalance de clases y comprobar que las variables no funcionen como sustitutos injustificados de atributos sensibles.

Modelos para separación y series temporales

Modelo	Cómo funciona	Uso financiero
SVM	Busca una frontera con margen amplio entre clases; con kernels puede representar fronteras no lineales.	Fraude, clasificación de solvencia y dirección de movimientos de mercado. Es eficaz en espacios de muchas variables, pero puede ser costoso en muestras grandes y difícil de explicar (Cortes & Vapnik, 1995).
RNN y LSTM	Procesan secuencias y conservan información de pasos anteriores. LSTM usa compuertas para retener o descartar información.	Series de precios, volatilidad, flujos de efectivo y comportamiento transaccional. LSTM atiende dependencias largas, aunque necesita muchas observaciones y controles contra sobreajuste (Hochreiter & Schmidhuber, 1997).
K-means	Agrupar observaciones alrededor de K centroides sin usar una etiqueta objetivo.	Segmentación de clientes, agrupación de activos y detección exploratoria de comportamientos inusuales. Es rápido, pero exige definir K, escalar variables y aceptar que los grupos dependen de distancia y forma.

Aplicación por problema

Predicción de precios. Una regresión sirve como línea base. Si hay suficientes datos secuenciales y una validación temporal estricta, LSTM puede explorar dependencias no lineales. Aun así, los precios cambian de régimen y una mayor precisión histórica no garantiza rentabilidad después de costos.

Detección de fraude. Bosques aleatorios y SVM suelen ser opciones prácticas para clasificar operaciones. También pueden combinarse con reglas y revisión humana. La métrica principal no debe ser solo exactitud: se necesitan precisión, recall, costo de falsos positivos y estabilidad.

Riesgo de crédito. La regresión lineal o logística ofrece una explicación clara; árboles y bosques pueden mejorar el desempeño al capturar umbrales. La decisión debe considerar explicabilidad, sesgos, calidad de datos, privacidad y capacidad de impugnación.

Portafolios. K-means puede agrupar activos con comportamientos similares y reducir concentración aparente. Random Forest o redes pueden generar señales, pero la optimización final debe incorporar restricciones, costos y pruebas fuera de muestra.

Comparación con la regresión lineal

Criterio	Regresión lineal	Aprendizaje automático
Complejidad	Baja. Pocos parámetros y entrenamiento rápido.	De media a alta. Requiere selección de hiperparámetros y validación.
Precisión	Buena cuando la relación es aproximadamente lineal.	Puede superar a la regresión con patrones no lineales y suficientes datos.
Interpretabilidad	Alta: los coeficientes tienen una lectura directa.	Variable: alta en árboles pequeños, menor en bosques, SVM y redes.
Procesamiento	Bajo costo y ejecución inmediata.	Mayor costo, especialmente en redes y búsqueda de hiperparámetros.
Aplicabilidad	Explicación, línea base, escenarios simples y muestras pequeñas.	Fraude, scoring, segmentación y series complejas.

Conclusión

No existe un algoritmo universalmente mejor. Para explicar relaciones y construir una línea base, la regresión es la primera opción. Para fraude y riesgo con umbrales o interacciones, un bosque aleatorio ofrece un equilibrio útil entre precisión y análisis de importancia de variables. Para series con dependencias largas, una LSTM puede ser adecuada si existe una muestra amplia y validación temporal. Para segmentación sin etiquetas, K-means es sencillo y rápido. En cualquier caso, el modelo debe compararse contra una línea base, probarse fuera de muestra y vigilarse después de su implementación.

En finanzas, un aumento pequeño de precisión no siempre compensa la pérdida de explicabilidad. El Financial Stability Board advierte que la falta de interpretabilidad o auditabilidad puede convertirse en un riesgo, y NIST recomienda gestionar el sistema durante todo su ciclo de vida mediante gobierno, mapeo, medición y gestión del riesgo (Financial Stability Board, 2017; Tabassi, 2023).

Reflexión personal para completar

Escribe 6 a 8 líneas: elige una aplicación financiera, explica qué modelo usarías y qué riesgo vigilarías.

Referencias

- Breiman, L. (2001). Random forests. *Machine Learning*, 45, 5-32. <https://doi.org/10.1023/A:1010933404324>
- Cámara de Diputados del H. Congreso de la Unión. (2025a). *Ley Federal de Protección de Datos Personales en Posesión de los Particulares* (última reforma DOF 14-11-2025). <https://www.diputados.gob.mx/LeyesBiblio/pdf/LFPDPPP.pdf>
- Cámara de Diputados del H. Congreso de la Unión. (2025b). *Ley de Protección y Defensa al Usuario de Servicios Financieros* (última reforma DOF 14-11-2025). <https://www.diputados.gob.mx/LeyesBiblio/pdf/LPDUSF.pdf>
- Cámara de Diputados del H. Congreso de la Unión. (2024). *Ley para Regular las Sociedades de Información Crediticia* (última reforma DOF 24-01-2024). <https://www.diputados.gob.mx/LeyesBiblio/pdf/LRSIC.pdf>
- Comisión Nacional para la Protección y Defensa de los Usuarios de Servicios Financieros. (2026). *Día Internacional de la Protección de Datos Personales*. <https://www.condusef.gob.mx/?idc=2708&idcat=3&p=contenido>
- Comisión Nacional para la Protección y Defensa de los Usuarios de Servicios Financieros. (s. f.). *Datos personales sensibles en servicios financieros*. <https://www.condusef.gob.mx/?idc=2056&idcat=1&p=contenido>
- Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20, 273-297. <https://doi.org/10.1007/BF00994018>
- Financial Stability Board. (2017). *Artificial intelligence and machine learning in financial services*. <https://www.fsb.org/2017/11/artificial-intelligence-and-machine-learning-in-financial-service/>
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. En *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability* (pp. 281-297). University of California Press.
- scikit-learn developers. (2026). *User guide*. https://scikit-learn.org/stable/user_guide.html
- Tabassi, E. (2023). *Artificial Intelligence Risk Management Framework AI RMF 1.0* (NIST AI 100-1). National Institute of Standards and Technology. <https://doi.org/10.6028/NIST.AI.100-1>